УДК 004.932.72

СРАВНИТЕЛЬНЫЙ АНАЛИЗ АРХИТЕКТУР YOLOv8 И RT-DETR ДЛЯ АВТОМАТИЗИРОВАННОГО ОБНАРУЖЕНИЯ ДЕФЕКТОВ ПЕЧАТНЫХ ПЛАТ

Д.Е. Квардонов[1], **Р.М. Толкачев**[1]

[1]*МГТУ им. Н.Э. Баумана, Москва, Россия*

Аннотация: В работе проводится сравнительное исследование архитектур YOLOv8n, YOLOv8s, YOLOv8m и RT-DETR-l для задачи автоматизированного обнаружения дефектов поверхности печатных плат. Для обучения использован датасет DeepPCB (693 изображения, 6 классов дефектов). Экспериментально показано, что YOLOv8m достигает наилучшего mAP@0.5 = 0.957, RT-DETR-l превосходит по mAP@0.5:0.95 = 0.561. YOLOv8s рекомендуется для промышленного применения как оптимальный по соотношению точности, скорости и компактности.

Ключевые слова: *детекция объектов, YOLOv8, RT-DETR, дефекты печатных плат, автоматизированный оптический контроль, глубокое обучение.*

Введение. Автоматизированный оптический контроль (AOI) печатных плат является ключевым этапом производства электроники, позволяющим выявлять дефекты на ранних стадиях и снижать производственный брак [1]. Традиционные алгоритмы компьютерного зрения, основанные на анализе шаблонов, чувствительны к вариациям освещения и геометрии платы. Современные методы глубокого обучения, в первую очередь семейство архитектур YOLO [2], обеспечивают высокую точность при реальном времени работы, что делает их перспективными для встраивания в производственные системы.

Трансформерные детекторы, в частности RT-DETR [3], демонстрируют улучшенную точность локализации объектов при строгих порогах IoU за счёт механизма внимания. Вместе с тем их вычислительная сложность может ограничивать применение в высокопроизводительных линиях. Существующие работы по детекции дефектов PCB, как правило, ограничены одной архитектурой: в [4] использован специализированный детектор на базе VGG16, в [1] — Faster R-CNN, тогда как сравнение современных однопроходных детекторов (YOLOv8) с трансформерными (RT-DETR) на данном классе задач в литературе не проводилось.

Цель настоящей работы — провести сравнительное исследование четырёх архитектур детекторов (YOLOv8n, YOLOv8s, YOLOv8m, RT-DETR-l) применительно к задаче автоматизированного обнаружения дефектов поверхности печатных плат (PCB, Printed Circuit Board) и определить оптимальное решение с учётом точности, скорости инференса и размера модели для внедрения в промышленные AOI-системы.

1. Набор данных и предобработка. В работе использован датасет DeepPCB (PKU-Market-PCB) [4], разработанный Пекинским университетом. Датасет содержит 693 изображения печатных плат с аннотациями шести типов дефектов: missing_hole (пропущенное отверстие), mouse_bite («укус мыши»), open_circuit (разрыв цепи), short (короткое замыкание), spur (шпора) и spurious_copper (лишняя медь). Изображения получены промышленной CCD-камерой высокого разрешения, дефекты размечены ограничивающими прямоугольниками в формате Pascal VOC XML.

Размер дефектов невелик: медианная нормализованная площадь bbox составляет 0.0004–0.0013 в зависимости от класса, что делает задачу сложной для стандартных детекторов, ориентированных на объекты среднего размера. Для подготовки к обучению аннотации Pascal VOC XML преобразованы в формат YOLO (нормализованные координаты cx, cy, w, h; индексы классов с нуля). Датасет разбит на обучающую (70%, 484 изображения), валидационную (15%, 104 изображения) и тестовую (15%, 105 изображений) выборки методом случайного перемешивания с фиксированным начальным состоянием (seed=42). На рисунке 1 представлены примеры изображений используемого датасета с аннотированными дефектами.

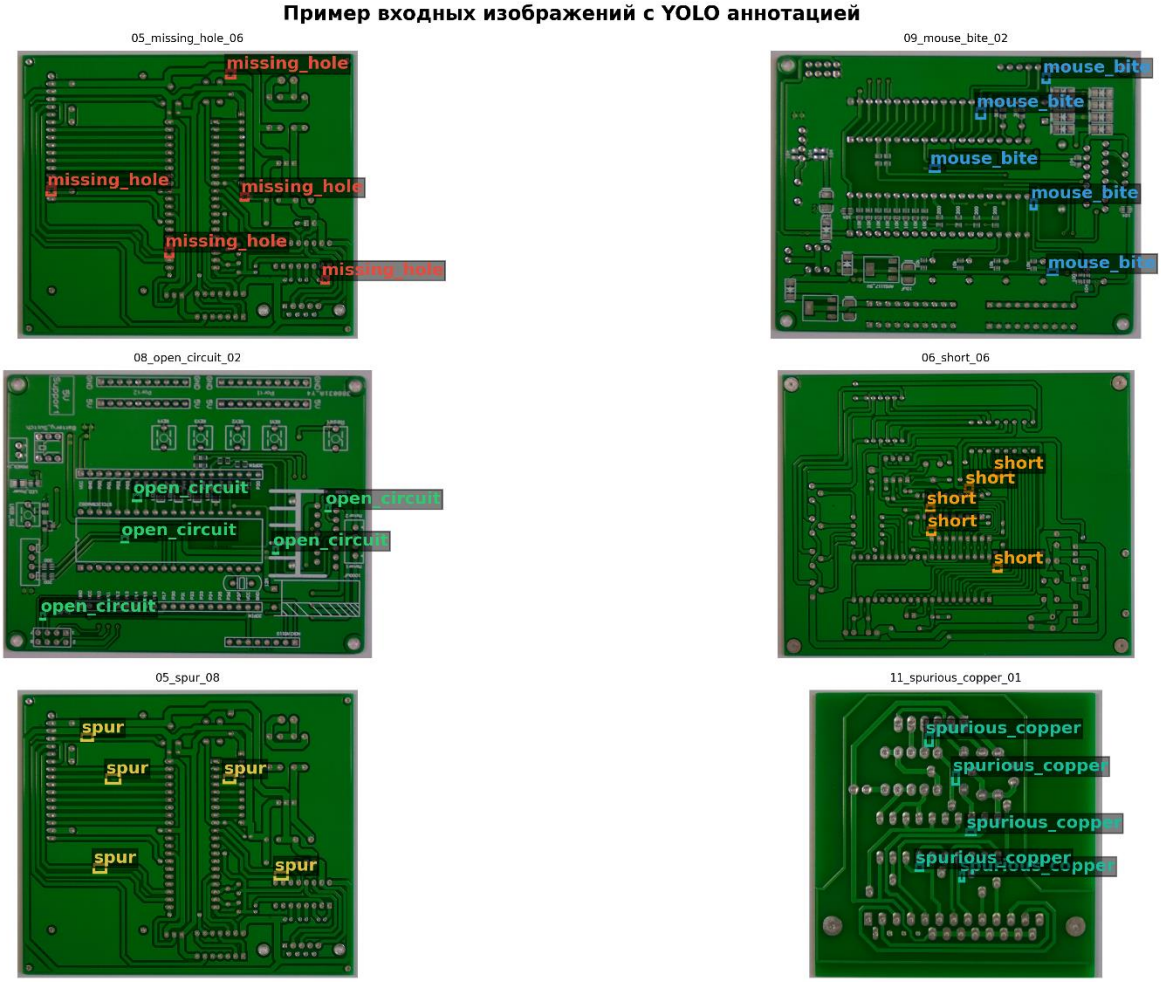

Рисунок 1. Примеры изображений из датасета DeepPCB с аннотированными дефектами

2. Методология. Все четыре модели обучены с весами, предобученными на датасете COCO, в идентичных условиях: 100 эпох (ранняя остановка при patience=20), размер входного изображения 640×640 пикселей, размер батча 16. Применялась аугментация: мозаичное смешивание (mosaic=1.0), MixUp (mixup=0.1), горизонтальное зеркалирование (fliplr=0.5), случайное изменение параметров HSV. Обучение выполнено на GPU NVIDIA GeForce RTX 3060 (12 ГБ VRAM) с использованием библиотеки Ultralytics 8.4.

Оценка производилась на тестовой выборке по метрикам mAP@0.5, mAP@0.5:0.95 (среднее по порогам IoU от 0.5 до 0.95 с шагом 0.05), Precision и Recall при пороге достоверности 0.25 и IoU=0.5. Скорость инференса измерялась как среднее время обработки одного изображения (мс/изображение) на GPU с предварительным прогревом.

3. Результаты. Сводные результаты сравнения моделей на тестовой выборке приведены в таблице 1.

Таблица 1. Сравнение архитектур детекторов на тестовой выборке

Модель	mAP@0.5	mAP@0.5:0.95	Precision	Recall	Размер

YOLOv8n	0.912	0.523	0.963	0.837	6.0 МБ
YOLOv8s	0.944	0.544	0.966	0.905	21.5 МБ
YOLOv8m	0.957	0.557	0.977	0.924	49.6 МБ
RT-DETR-l	0.953	0.561	0.980	0.910	63.2 МБ

Из таблицы 1 видно, что YOLOv8m достигает наилучшего значения mAP@0.5 = 0.957, тогда как RT-DETR-l лидирует по mAP@0.5:0.95 = 0.561, что свидетельствует о более точной локализации дефектов при строгих порогах IoU. Вместе с тем RT-DETR-l значительно уступает по скорости (80.4 мс/изображение против 36.5 мс у YOLOv8s) и размеру модели (63.2 МБ против 21.5 МБ).

Детальная разбивка AP@0.5 по классам дефектов представлена на рисунке 2.

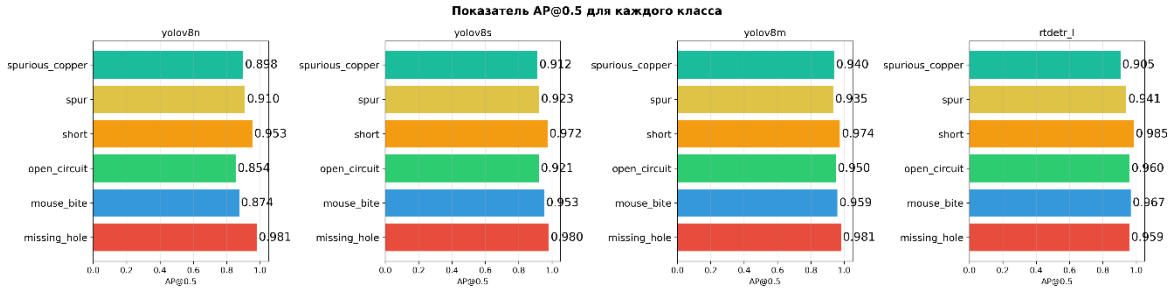

Рисунок 2. Сравнение AP@0.5 четырёх архитектур по классам

На рисунке 3 представлены примеры обнаружения дефектов с помощью модели YOLOv8m.

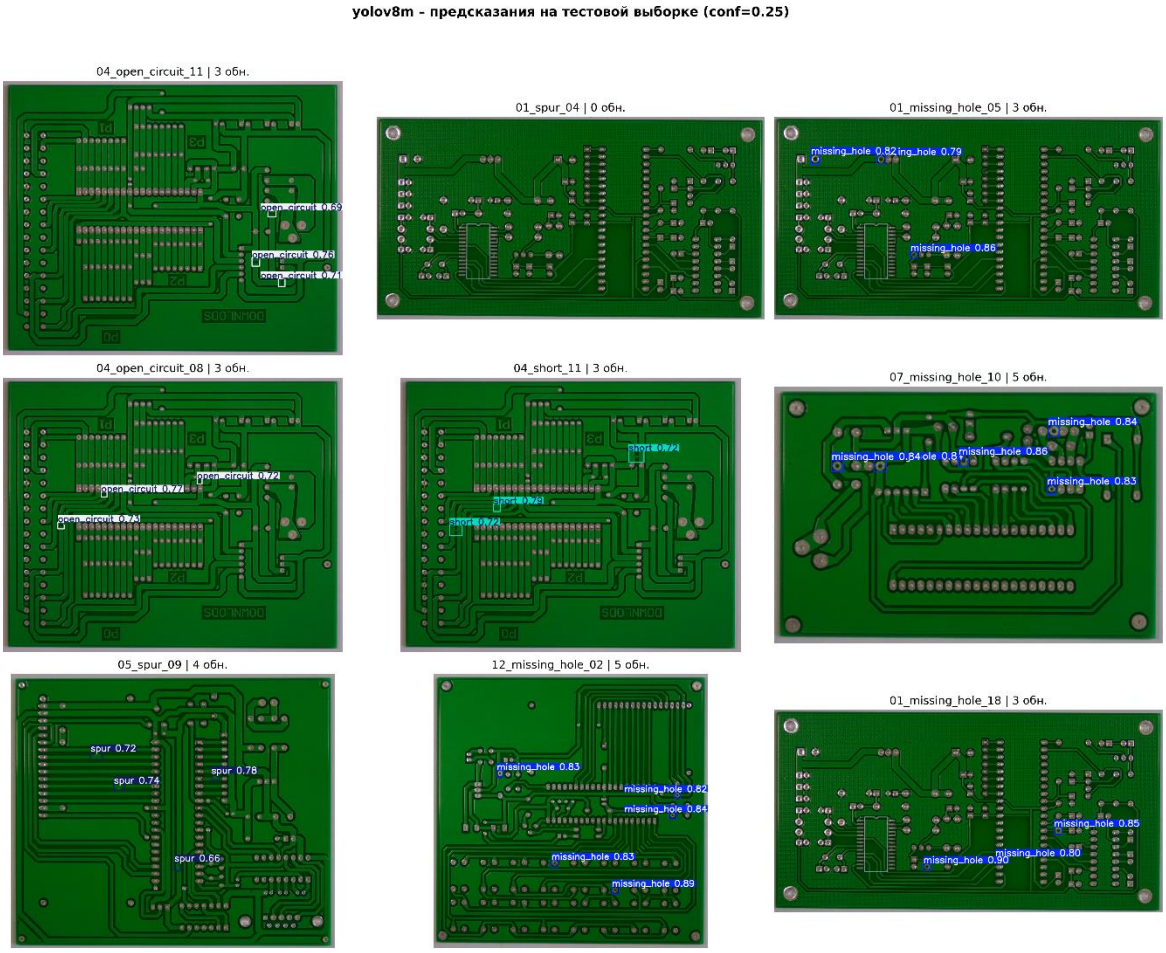

Рисунок 3. Примеры обнаружения дефектов моделью YOLOv8m на тестовых изображениях

На рисунке 4 представлен пример верно обнаруженных дефектов для класса missing_hole (пропущенное отверстие) с помощью модели YOLOv8m.

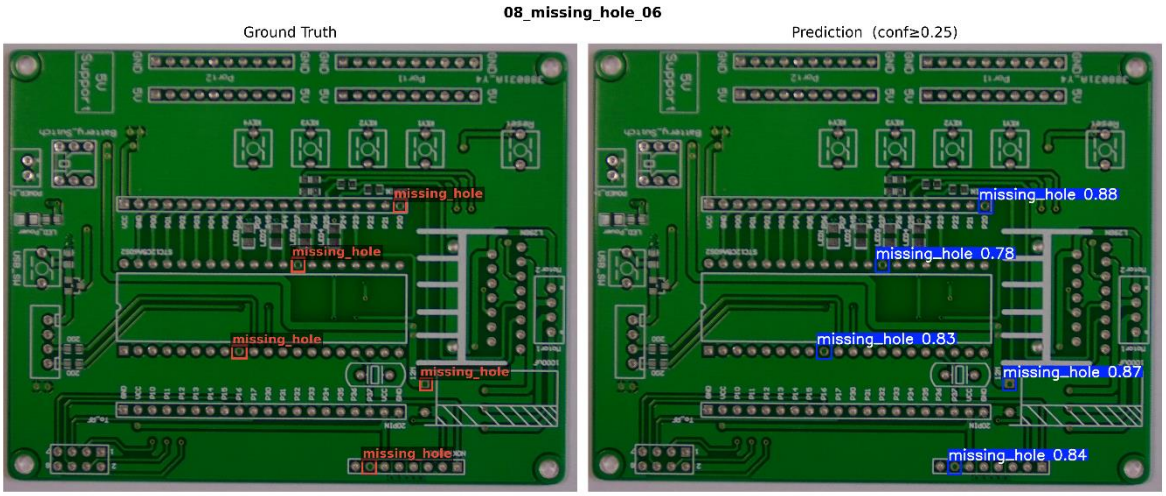

Рисунок 4. Пример верно обнаруженных дефектов моделью YOLOv8m для класса missing_hole

На рисунке 5 представлен пример частично обнаруженных дефектов для класса short (короткое замыкание) с помощью модели YOLOv8m.

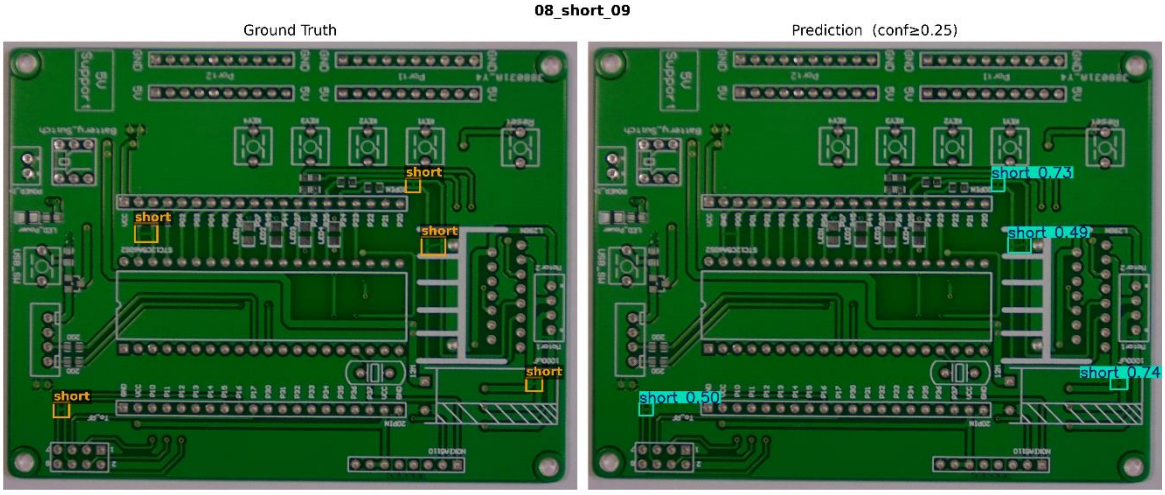

Рисунок 5. Пример частично обнаруженных дефектов моделью YOLOv8m для класса short

Заключение. В работе проведено сравнительное исследование архитектур YOLOv8n, YOLOv8s, YOLOv8m и RT-DETR-l для задачи автоматизированного обнаружения дефектов поверхности печатных плат на датасете DeepPCB. Разработан пайплайн конвертации аннотаций Pascal VOC XML в формат YOLO.

Экспериментально установлено: (1) YOLOv8m обеспечивает наилучший mAP@0.5 = 0.957; (2) RT-DETR-l превосходит по точной локализации — mAP@0.5:0.95 = 0.561, однако в 2.2 раза медленнее; (3) YOLOv8s является оптимальным выбором для промышленных AOI-систем с учётом баланса точности (mAP@0.5 = 0.944), скорости (36.5 мс/изображение) и компактности модели (21.5 МБ); (4) класс short остаётся наиболее трудным для всех архитектур [5]. Направлениями дальнейших исследований являются применение входного разрешения 1280×1280 для улучшения детекции мелких дефектов, а также тестирование на реальных производственных данных с более широким спектром типов дефектов.

Литература

1. Gao, Y., Lin, X. Deep learning for PCB surface defect detection // Journal of Manufacturing Systems. 2021. Vol. 58. P. 91–108.

2. Jocher, G. et al. Ultralytics YOLOv8 [Электронный ресурс]. 2023. URL: https://github.com/ultralytics/ultralytics (дата обращения: 01.04.2026).

3. Zhao, Y. et al. DETRs Beat YOLOs on Real-time Object Detection // Proceedings of CVPR. 2024. P. 16965–16974.

4. Tang, J. et al. Online PCB defect detector on a new PCB defect dataset. arXiv:1902.06197. 2019.

5. Redmon, J. et al. You Only Look Once: Unified, Real-Time Object Detection // Proceedings of CVPR. 2016. P. 779–788.

COMPARATIVE ANALYSIS OF YOLOv8 AND RT-DETR ARCHITECTURES FOR AUTOMATED PCB DEFECT DETECTION

D.E. Kvardonov[1], **R.M. Tolkachev**[1]

[1]*BMSTU, Moscow, Russia*

Abstract: This paper presents a comparative study of four object detection architectures — YOLOv8n, YOLOv8s, YOLOv8m and RT-DETR-l — for automated PCB surface defect detection using the DeepPCB dataset (693 images, 6 defect classes). YOLOv8m achieved the best mAP@0.5 = 0.957; RT-DETR-l led on mAP@0.5:0.95 = 0.561 with twice the inference latency. YOLOv8s is recommended as the optimal accuracy–speed–size trade-off for real-time AOI systems.

Keywords: *object detection, YOLOv8, RT-DETR, PCB defect detection, automated optical inspection, deep learning.*