УДК 004.932.72

Сравнительный анализ архитектур YOLOv8 и RT-DETR для автоматизированного обнаружения дефектов печатных плат

Квардонов Дмитрий Евгеньевич[1]
Толкачёв Родион Михайлович[1]
Канев Антон Игоревич[1] (научный руководитель)

[1]*МГТУ им. Н.Э. Баумана, Москва, Россия*

В работе проводится сравнительное исследование архитектур YOLOv8n, YOLOv8s, YOLOv8m и RT-DETR-l для задачи автоматизированного обнаружения дефектов поверхности печатных плат. Для обучения использован датасет DeepPCB (693 изображения, 6 классов дефектов). Экспериментально показано, что YOLOv8m достигает наилучшего mAP@0.5 = 0.957, RT-DETR-l превосходит по mAP@0.5:0.95 = 0.561. YOLOv8s рекомендуется для промышленного применения как оптимальный по соотношению точности, скорости и компактности.

***Ключевые слова**: детекция объектов, YOLOv8, RT-DETR, дефекты печатных плат, автоматизированный оптический контроль, глубокое обучение.*

Введение. Автоматизированный оптический контроль (AOI) печатных плат является важным этапом производства электроники, позволяющим выявлять дефекты на ранних стадиях и снижать производственный брак [1]. Традиционные алгоритмы компьютерного зрения, основанные на анализе шаблонов, чувствительны к вариациям освещения и геометрии платы. Современные методы глубокого обучения, в первую очередь семейство архитектур YOLO [2], обеспечивают высокую точность при реальном времени работы, что делает их перспективными для встраивания в производственные системы.

Трансформерные детекторы, в частности RT-DETR [3], демонстрируют улучшенную точность локализации объектов при строгих порогах IoU за счёт механизма внимания. Вместе с тем их вычислительная сложность может ограничивать применение в высокопроизводительных линиях. Применение DETR-подобных архитектур к дефектоскопии печатных плат рассматривалось в ряде работ [4], однако в них, как правило, исследуется одна модифицированная архитектура без прямого сравнения с семейством YOLOv8 в идентичных условиях обучения. В более ранних работах применялись одиночные архитектуры: в [5] описывается детектор на базе VGG16, в [1] упоминается Faster R-CNN. Прямое сравнение четырёх конфигураций (YOLOv8n/s/m и RT-DETR-l) на датасете DeepPCB при единых гиперпараметрах обучения ранее не проводилось.

Цель настоящей работы – провести сравнительное исследование четырёх архитектур детекторов (YOLOv8n, YOLOv8s, YOLOv8m, RT-DETR-l) применительно к задаче автоматизированного обнаружения дефектов поверхности печат-

ных плат (PCB, Printed Circuit Board) и определить оптимальное решение с учётом точности, скорости инференса и размера модели для внедрения в промышленные AOI-системы.

1. Набор данных и предобработка. В работе использован датасет DeepPCB (PKU-Market-PCB) [5], разработанный Пекинским университетом. Датасет содержит 693 изображения печатных плат с аннотациями шести типов дефектов: missing_hole (пропущенное отверстие), mouse_bite («укус мыши»), open_circuit (разрыв цепи), short (короткое замыкание), spur (шпора) и spurious_copper (лишняя медь). Изображения получены промышленной CCD-камерой высокого разрешения, дефекты размечены ограничивающими прямоугольниками в формате Pascal VOC XML.

Размер дефектов невелик: медианная нормализованная площадь bbox составляет 0.0004-0.0013 в зависимости от класса, что делает задачу сложной для стандартных детекторов, ориентированных на объекты среднего размера. Для подготовки к обучению аннотации Pascal VOC XML преобразованы в формат YOLO (нормализованные координаты cx, cy, w, h; индексы классов с нуля). Датасет разбит на обучающую (70%, 484 изображения), валидационную (15%, 104 изображения) и тестовую (15%, 105 изображений) выборки методом случайного перемешивания с фиксированным начальным состоянием (seed=42). На рис.1 представлены примеры изображений используемого датасета с аннотированными дефектами.

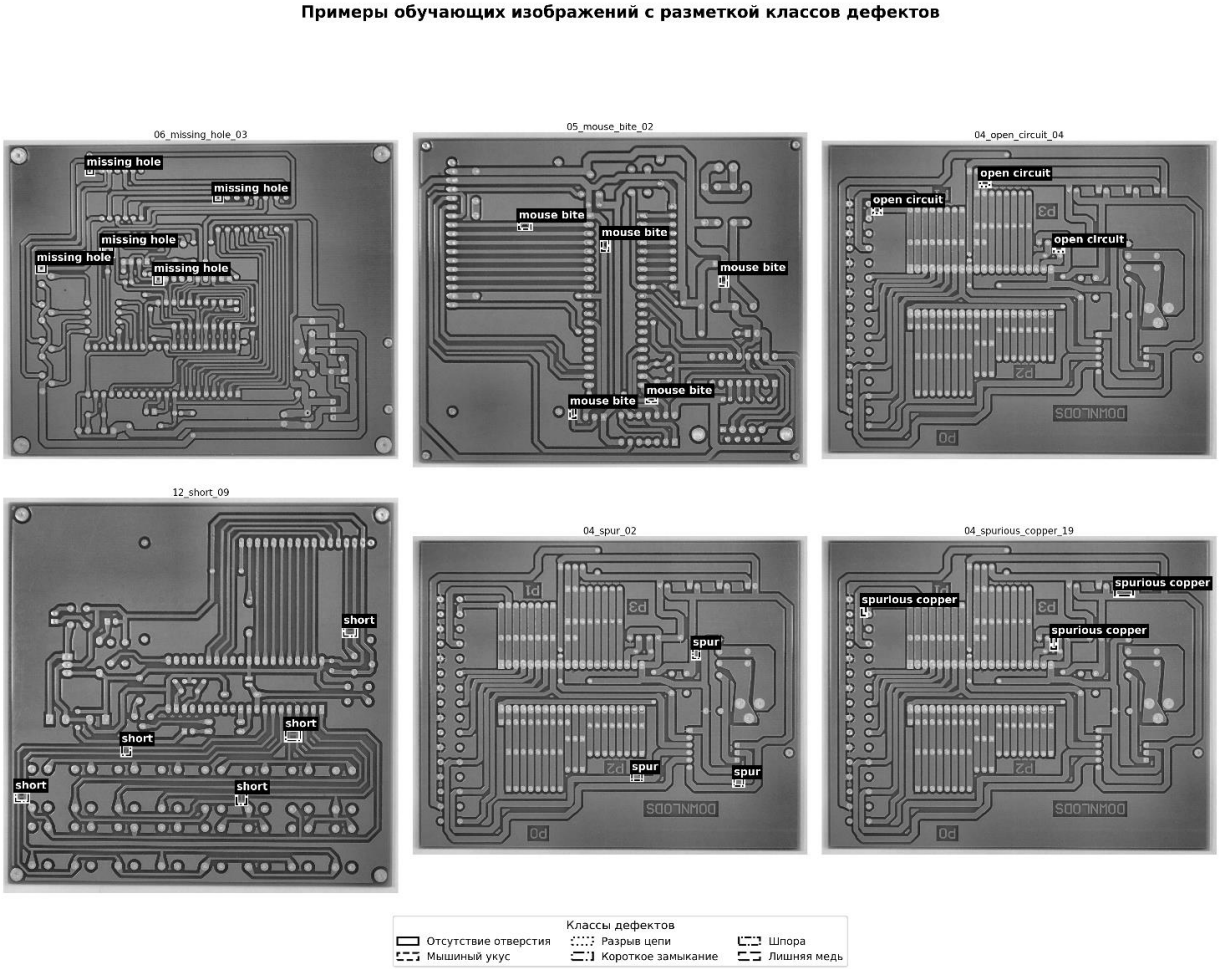

Рис. 1. Примеры изображений из датасета DeepPCB с аннотированными дефектами

2. Методология. Все четыре модели обучены с весами, предобученными на датасете COCO, в идентичных условиях: 100 эпох (ранняя остановка при patience=20), размер входного изображения 640×640 пикселей, размер батча 32. Оптимизатор AdamW (значения по умолчанию Ultralytics); weight_decay=0.0005. Применялась аугментация: мозаичное смешивание (mosaic=0.5), горизонтальное зеркалирование (fliplr=0.5), случайное изменение HSV (hsv_h=0.015, hsv_s=0.5, hsv_v=0.4). Обучение выполнено на GPU NVIDIA GeForce RTX 3060 (12 ГБ VRAM) с использованием библиотеки Ultralytics 8.4.

Оценка производилась на тестовой выборке по метрикам mAP@0.5, mAP@0.5:0.95 (среднее по порогам IoU от 0.5 до 0.95 с шагом 0.05), Precision и Recall при пороге достоверности conf=0.25 и IoU=0.5. Пониженный порог conf=0.25 обоснован малой нормализованной площадью bbox (0.0004-0.0013): при стандартном пороге 0.5 модели систематически занижают уверенность для мелких объектов, что приводит к избыточным ложноотрицательным срабатываниям. Скорость инференса определялась усреднением по 10 тестовым изображениям (batch=1) после однократного прогрева с помощью time.perf_counter; значения отражают сквозную латентность пайплайна (предобработка + инференс + постобработка) в Python-приложении на GPU.

3. Результаты. Сводные результаты сравнения моделей на тестовой выборке приведены в таблице 1.

Таблица 1

Сравнение архитектур детекторов на тестовой выборке

Модель	mAP@0.5	mAP@0.5:0.95	Precision	Recall	Размер	Инференс
YOLOv8n	0.912	0.523	0.963	0.837	6.0 МБ	46.3 мс
YOLOv8s	0.944	0.544	0.966	0.905	21.5 МБ	51.1 мс
YOLOv8m	0.957	0.557	0.977	0.924	49.6 МБ	59.8 мс
RT-DETR-l	0.953	0.561	0.980	0.910	63.2 МБ	78.8 мс

Из таблицы 1 видно, что YOLOv8m достигает наилучшего значения mAP@0.5 = 0.957, тогда как RT-DETR-l лидирует по mAP@0.5:0.95 = 0.561, что свидетельствует о более точной локализации дефектов при строгих порогах IoU. Вместе с тем RT-DETR-l значительно уступает по скорости (78.8 мс/изображение против 51.1 мс у YOLOv8s) и размеру модели (63.2 МБ против 21.5 МБ). Приоритет метрики определяется требованиями конкретного производства: mAP@0.5 подойдет для систем с допустимой погрешностью локализации, а mAP@0.5:0.95 – для прецизионного контроля. Для обоснования выбора YOLOv8s рассчитан показатель предельной эффективности: прирост mAP при переходе YOLOv8n→s составляет +0.032 при увеличении размера на 15.5 МБ (2.1×10^{-3} mAP/МБ), тогда как переход s→m даёт лишь +0.013 при +28.1 МБ (0.46×10^{-3} mAP/МБ), наблюдается снижение эффективности в 4.5 раза.

Детальная разбивка AP@0.5 по классам дефектов представлена на рис. 2.

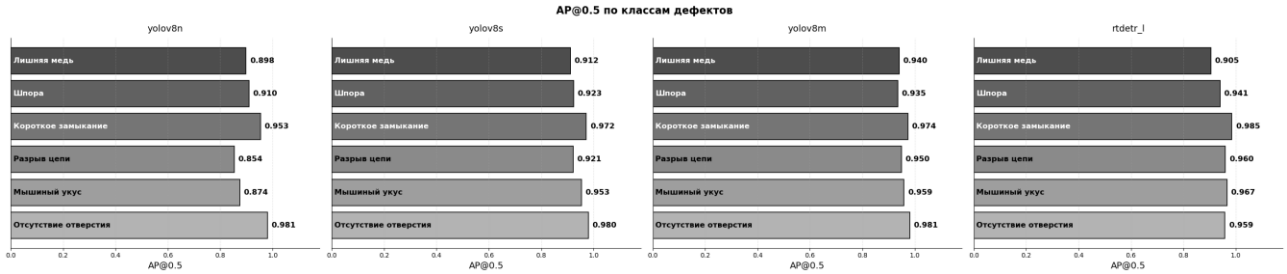

Рис. 2. Сравнение AP@0.5 четырёх архитектур по классам

Анализ AP@0.5 по классам (рис. 2) выявляет, что наиболее сложными для всех архитектур являются разрыв цепи (open_circuit, среднее AP = 0.921) и лишняя медь (spurious_copper, среднее AP = 0.914). Эти классы представляют дефекты с нечёткими текстурными границами и переменной формой. Наиболее точно обнаруживается пропущенное отверстие (среднее AP = 0.975): его геометрия хорошо описывается bbox.

На рисунке 3 представлен пример верно обнаруженных дефектов для класса missing_hole (пропущенное отверстие) с помощью модели YOLOv8m.

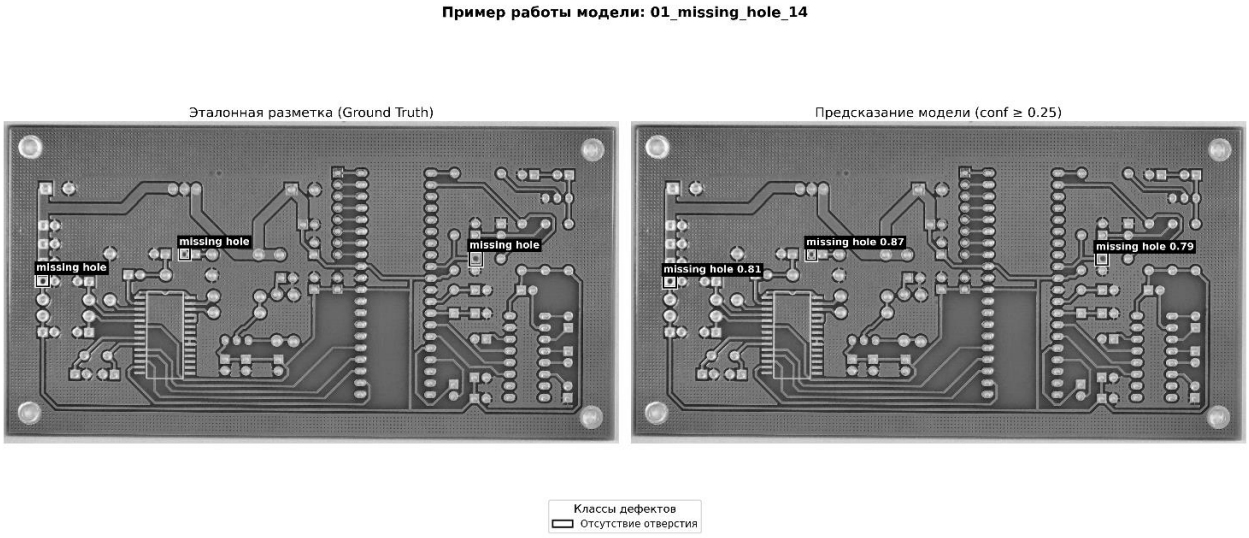

Рис. 3. Пример верно обнаруженных дефектов моделью YOLOv8m для класса missing_hole

На рис. 4 представлен пример частично обнаруженных дефектов для класса short (короткое замыкание) с помощью модели YOLOv8m.

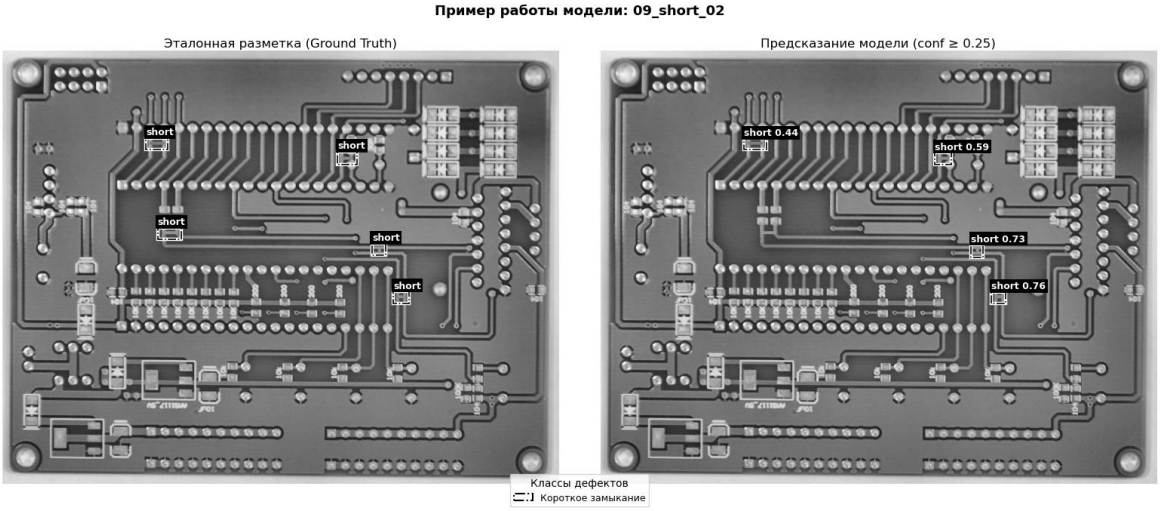

Рис. 4. Пример частично обнаруженных дефектов моделью YOLOv8m для класса short

Заключение. В работе проведено сравнительное исследование архитектур YOLOv8n, YOLOv8s, YOLOv8m и RT-DETR-l для задачи автоматизированного обнаружения дефектов поверхности печатных плат на датасете DeepPCB. Разработан пайплайн конвертации аннотаций Pascal VOC XML в формат YOLO.

Экспериментально установлено: (1) YOLOv8m обеспечивает наилучший mAP@0.5 = 0.957; (2) RT-DETR-l превосходит по точной локализации — mAP@0.5:0.95 = 0.561, однако в 1.3 раза медленнее YOLOv8m и в 2.9 раза крупнее; (3) YOLOv8s является оптимальным выбором для промышленных AOI-систем; (4) наиболее трудными для всех архитектур классами являются разрыв цепи и лишняя медь (среднее AP = 0.921 и 0.914 соответственно). Ввиду однократного разбиения датасета (seed=42) доверительные интервалы для mAP не вычислялись; кросс-валидация является направлением дальнейших исследований наряду с применением входного разрешения 1280×1280 для улучшения детекции мелких дефектов и тестированием на реальных производственных данных.

Литература

[1] Gao Y., Lin X. Deep learning for PCB surface defect detection // Journal of Manufacturing Systems. 2021. Vol. 58. Pp. 91–108.

[2] Jocher G. et al. Ultralytics YOLOv8: документация. URL: https://github.com/ultralytics/ultralytics (дата обращения 01.04.2026).

[3] Zhao Y. et al. DETRs Beat YOLOs on Real-time Object Detection // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024. Pp. 16965–16974.

[4] Li Q. et al. PCB-DETR: A Detection Network of PCB Surface Defect with Spatial Attention Offset Module // IEEE Access. 2024. Vol. 12. Pp. 158436–158445. https://doi.org/10.1109/ACCESS.2024.3486176

[5] Tang J. et al. Online PCB defect detector on a new PCB defect dataset // arXiv. 2019. arXiv:1902.06197.

Comparative analysis of YOLOv8 and RT-DETR architectures for automated pcb defect detection

Kvardonov Dmitry Evgenevich[1]
Tolkachev Rodion Mikhailovich[1]
Kanev Anton Igorevich[1] (scientific advisor)

[1]*BMSTU, Moscow, Russia*

This paper presents a comparative study of four object detection architectures — YOLOv8n, YOLOv8s, YOLOv8m and RT-DETR-l — for automated PCB surface defect detection using the DeepPCB dataset (693 images, 6 defect classes). YOLOv8m achieved the best mAP@0.5 = 0.957; RT-DETR-l led on mAP@0.5:0.95 = 0.561 with twice the inference latency. YOLOv8s is recommended as the optimal accuracy–speed–size trade-off for real-time AOI systems.

***Keywords**: object detection, YOLOv8, RT-DETR, PCB defect detection, automated optical inspection, deep learning.*